


Predicciones en el espacio: ¿Cuántos satélites y desechos podremos tener?



Autores: Ramiro Barone, Sergio Rodriguez, Leila Saker & Federico Zuriaga

Mentor: Enzo Manolucos

Contenido

01 Descripción y
objetivos del
proyecto


02 Análisis y visualización
de los datos

03 Curación y
preparación de
los datos

04 Modelo de aprendizaje
no supervisado

05 Modelo de aprendizaje
supervisado

06 Resultados y
Conclusiones



01


Descripción y objetivo del proyecto

- ★ ¿Cómo ha evolucionado la cantidad de satélites en los últimos años?
- ★ ¿Cuál es la vida útil real de un satélite?
- ★ ¿Qué países generan más desechos en el espacio?
- ★ ¿Podemos predecir la cantidad de desechos espaciales en los próximos años?

Desarrollar un modelo predictivo y de clasificación de objetos en órbita terrestre.

01

Dataset analizado




Space-Trac

k




Union of Concerned
Scientists

- ★ Tamaño y masa de los satélites.
- ★ Órbita según el período orbital.
- ★ Propósito de cada satélite.
- ★ Vida útil esperada de los satélites.




02


Análisis y visualización de los datos



Tipos de objetos encontrados en órbita



Países con más satélites en órbita (top 10)





Total de satélites en órbita:
20.368

Promedio de vida según su órbita

Leo: 4,56 años

Meo: 9,55 años

Geo: 13,77 años



Evolucion del nº de satélites con el tiempo


Conclusiones previas



En la visualización de los datos, pudimos sacar algunas conclusiones:


- ★ Hay países más propensos a generar basura.
- ★ El propósito y tipo de órbita nos indican su posible vida útil.
- ★ Tenemos datos outliers que introducen ruido en el análisis.
- ★ La cantidad de basura fue creciendo exponencialmente durante los últimos años.





03



Curación y preparación de los datos



★ Limpieza de datos


Eliminamos variables poco informativas, cuya contribución al modelo es mínima o nula, o que presentaban un % muy alto de datos faltantes:

- ★ Detailed Purpose
- ★ Comment, CommentCode
- ★ Country
- ★ Dry Mass
- ★ Power
- ★ Apogee, Perigee, Inclination, Period
- ★ 'COSPAR_Number', 'NORAD Number'



Curación de datos

- ★ Convertimos las columnas 'DECAY' y 'Date of Launch' a formato datetime para poder trabajar con fechas.
- ★ Transformamos datos categóricos a numéricos:
 - La variable 'Class_of_Orbit' tiene un cierto orden, le aplicamos OrdinalEncoder
 - Para el resto de las variables, aplicamos OneHotEncoder.
- ★ Revisamos los datos faltantes, y los completamos con el algoritmo MICE.
- ★ Eliminamos valores outliers, para realizar un mejor escalamiento.
- ★ Escalamos los datos:
 - Columnas cuyas distribuciones no son normales, con MinMaxScaler.
 - Columnas con distribuciones normales, con StandarScaler.




PCA

Los primeros 3 componentes explican el 78.4% de la varianza.



Se puede trabajar con los primeros 2 o 3 componentes y conservar más del 75% de la información original.



División de los datos


- ★ Seleccionamos las variables predictoras y la variable objetivo.
- ★ Dividimos los datos en entrenamiento (para ajustar el modelo) y test (para evaluar rendimiento) usando `train_test_split` de `scikit-learn`.



Train (80%)




Test (20%)



04

Modelo de aprendizagem no supervisionado






Clustering con DBSCAN

Procedimos primero con un análisis de clusters con DBSCAN puesto que no requiere elegir previamente un K óptimo.

Los puntos que no pertenezcan a ningún cluster se marcan como -1 (ruido).



Clusters con DBSCAN en 3D (PCA)







Clustering con K-Means

Probamos varios valores de K y medimos dos métricas:

Inertia → para el método del codo.


Coefficiente de silueta → para ver qué tan bien separados están los clusters.



Visualización (2 componentes principales)





★ Clustering con Mezcla de Gaussianas



Visualización (2 componentes principales)


Clusters con GMM en 3D (PCA)






05

Modelo de aprendizaje supervisado



★ Decision Tree y Random Forest sin PCA




Modelo	MAE	RMSE	R ²	OOB Score
DT	0.081	0.376	0.888	—
RF	0.08	0.311	0.923	0.917

Aunque ambos modelos funcionan bien, Random Forest ofrece predicciones más precisas y confiables.




Random Forest sin PCA - Ajuste de hiperparámetros



Modelo	R ²	OOB Score
RF inicial	0.923	0.917
RF optimizado	0.917	0.919

Al comparar el modelo inicial y el optimizado, no encontramos diferencias significativas.

★ Decision Tree y Random Forest con PCA




Modelo	MAE	RMSE	R ²
DT (PCA)	0.081	0.376	0.888
RF (PCA)	0.004	0.039	0.999

El uso de PCA mejora el desempeño del modelo Random Forest.


El modelo Decision Tree no se ve afectado por aplicar PCA.

★ Gradient Boosting Regressor



Modelo	MAE	RMSE	R ²
SGDRegressor	0.272	0.576	0.438

Aunque SGD Regressor mostró buenas métricas inicialmente, su rendimiento empeoró al evaluar con el conjunto de validación, indicando menor capacidad de generalización.



06 Resultados y Conclusiones

- ★ Realizamos una visualización y un análisis exploratorio de los datos.
- ★ Llevamos a cabo la curación y preparación de los datos, con el fin de aplicar nuestro modelo de manera adecuada.
- ★ Los distintos enfoques de clustering no supervisado (DBSCAN, K-Means y Mezcla de Gaussianas) no lograron revelar estructuras claras en los datos.
- ★ Se probaron tres modelos de aprendizaje supervisado: Decision Tree, Random Forest y SGD Regressor.
 - A Decision Tree y Random Forest los entrenamos con y sin PCA para comparar resultados.
 - Se evaluaron con MAE, RMSE y R^2 .
 - El mejor desempeño lo obtuvo Random Forest con PCA.
 - Aunque SGD Regressor mostró buenas métricas inicialmente, su rendimiento empeoró al evaluar con el conjunto de validación, indicando menor capacidad de generalización.